

Procesamiento de Datos

Procesamiento de datos

- El procesamiento de datos implica:
 - transformar datos **sin** procesar en información valiosa para las empresas
- En general, los científicos de datos procesan datos, lo que incluye:
 - recopilarlos,
 - organizarlos,
 - limpiarlos,
 - verificarlos,
 - analizarlos

Procesamiento de datos

- Convertirlos los datos en formatos legibles:
 - como gráficos o
 - Documentos.
- Es la acumulación y manipulación de elementos de datos para producir información significativa

ETL: Extract, Transform, Load

- Extracción, Transformación y Carga.
- ETL es un proceso utilizado en:
 - la informática y
 - en la gestión de datos
- Esto para mover y transformar datos desde múltiples fuentes de origen hacia una base de datos o almacén de datos centralizado.

ETL: Extract, Transform, Load

- Convertir datos crudos en:
 - información útil y
 - significativa
- que pueda ser utilizada para:
 - la toma de decisiones,
 - la optimización de procesos y
 - la generación de valor para las organizaciones.

Extracción (Extract):

- En esta fase, los datos se extraen de diferentes fuentes, como:
 - bases de datos,
 - archivos planos,
 - servicios web, entre otros.
- Esta extracción se realiza de acuerdo con ciertos criterios definidos previamente.

Transformación (Transform):

- Después de la extracción, los datos pueden requerir modificaciones para:
 - ajustarse al esquema o
 - formato deseado en el almacén de datos.
- Esto puede incluir:
 - limpieza de datos,
 - conversión de formatos,
 - enriquecimiento con datos adicionales, o
 - cualquier otra manipulación necesaria.

Carga - Load

- Una vez que los datos han sido extraídos y transformados según sea necesario, se cargan en el destino final.
- Puede ser:
 - un almacén de datos,
 - un data lake,
 - una base de datos relacional, o
 - cualquier otro repositorio de datos que se esté utilizando para el análisis o la consulta posterior.

Funciones (versión 1)

- El procesamiento de datos puede involucrar diversas funciones, entre ellas:
- Validación - Asegurar que los datos suministrados son limpio, correcto y útil.
- Clasificación - Ordena elementos de cierta secuencia y / o en diferentes conjuntos.
- Recapitulación - Reducir los detalles de los datos a sus principales puntos.
- Agregación - Combinación de múltiples piezas de datos.
- Análisis - La colección, organización, análisis, interpretación y presentación de datos.
- Información - Lista detallada o resumen de los datos de información computarizada

Funciones (versión 2)

- **Captura de datos:** Implica recopilar datos desde diversas fuentes, como sensores, dispositivos, formularios en línea, sistemas transaccionales, entre otros.
- **Almacenamiento de datos:** Consiste en guardar los datos de manera estructurada en sistemas de almacenamiento adecuados, como bases de datos, data lakes, o sistemas de archivos, garantizando su integridad y disponibilidad para su procesamiento posterior.
- **Limpieza de datos:** Es el proceso de identificar y corregir errores, duplicados, inconsistencias y valores atípicos en los datos para garantizar su calidad y fiabilidad. Esto puede incluir la estandarización de formatos, la eliminación de registros redundantes o la imputación de valores faltantes.
- **Transformación de datos:** Involucra la modificación de la estructura, el formato o el contenido de los datos para adaptarlos a los requisitos específicos de un sistema o aplicación. Esto puede incluir la normalización de datos, la agregación, la concatenación, la derivación de nuevas variables, entre otros.

Funciones (versión 2)

- **Análisis de datos:** Implica aplicar técnicas y algoritmos estadísticos, matemáticos o de inteligencia artificial para descubrir patrones, tendencias, relaciones o insights dentro de los datos. El análisis de datos puede ayudar a tomar decisiones informadas, identificar oportunidades o resolver problemas.
- **Visualización de datos:** Consiste en representar los resultados del análisis de datos de manera gráfica o visual, utilizando gráficos, tablas, mapas u otras herramientas visuales. La visualización de datos facilita la comprensión y la comunicación de la información contenida en los datos.
- **Entrega de datos:** Implica proporcionar los resultados del procesamiento y análisis de datos de manera oportuna y en un formato adecuado para su consumo por parte de los usuarios finales. Esto puede incluir informes, dashboards interactivos, APIs, exportaciones a sistemas externos, entre otros.

Repositorio

- Kaggle
 - <https://www.kaggle.com>
- Go to Datasets
 - Ejemplo: <https://www.kaggle.com/datasets/datasnaek/chess>

Awk

- AWK es un lenguaje de programación
- Herramienta de procesamiento de texto
- Utilizada principalmente en entornos de sistemas Unix y Unix-like.
- Fue creado originalmente en los años 70 por Alfred Aho, Peter Weinberger y Brian Kernighan (de ahí las iniciales "AWK") en los laboratorios Bell de AT&T.
- AWK se utiliza para procesar y manipular datos estructurados en archivos de texto, como registros o líneas de datos separadas por delimitadores, como comas o espacios.

Awk

Algunas de las características:

- Patrones y acciones:
 - AWK se basa en un paradigma de "patrón-acción", donde se especifican patrones que determinan qué líneas de entrada deben ser procesadas, y acciones que se ejecutan en esas líneas que cumplen con los patrones.
- Extracción y manipulación de datos:
 - AWK es especialmente útil para extraer y manipular datos específicos dentro de archivos de texto. Puede realizar operaciones como búsqueda, filtrado, agregación, cálculos numéricos y manipulaciones de cadena de texto.
- Procesamiento de archivos estructurados:

Awk

- Automatización de tareas:
 - AWK se puede utilizar para automatizar tareas repetitivas o para realizar análisis de datos simples en archivos de texto. Es útil en situaciones donde se necesita procesar grandes volúmenes de datos de manera rápida y eficiente.
- Herramienta de línea de comandos:
 - AWK se puede invocar desde la línea de comandos de Unix o Unix-like, lo que lo hace fácilmente accesible y útil para tareas de scripting y procesamiento de datos en entornos de línea de comandos.
- Útil para tareas de análisis y manipulación de archivos de texto estructurados

AwK

- Instalar Awk
- [How to run an awk commands in Windows? - Stack Overflow](https://stackoverflow.com/questions/21927944/how-to-run-an-awk-commands-in-windows) :
<https://stackoverflow.com/questions/21927944/how-to-run-an-awk-commands-in-windows>